

## 综合课题研究

Lecturer: Feng Chen      chenfeng@mail.tsinghua.edu.cn

TA: Tianren Zhang, Yizhou Jiang, Chongkai Gao      zhangtr22,jyz20,gck20@mails.tsinghua.edu.cn

## 1 基本要求

- A. 本次大作业采用分组形式进行。每 1 ~ 2 名同学可以自由组合为一个小组，共同协作讨论完成文献调研、仿真实验、展示 PPT 以及附录文档，并派一名代表将所有相关内容（PPT、文档、仿真程序等）一起压缩打包（以组员“姓名 1 姓名 2 学号 1 学号 2”形式进行压缩文件命名）上传网络学堂，同时在“作业内容”中再次注明小组成员。其他小组成员也要提交作业，但无需重复上传附件，只需在“作业内容”中注明小组成员，并写明由哪位成员负责提交附件。
- B. 作业成果以展示 PPT 为主，其内容包含作业中各项要求所对应的技术路线、理论推导、算法设计、实现方法、数值实验结果等内容；各项要求间详略分配可自行安排，整体篇幅以支撑 10 分钟的公开展示为宜。附录文档主要包括作业中所涉及，但不宜以 PPT 形式展示的诸细节，如详细推导过程、算法设计思路、实验数据整理、代码自述文件、关键参考文献等，具体形式和内容可根据需要自行安排。
- C. 展示内容应充分说明问题的解决思路，以及理论或算法的特点，结合自己的理解给出相应结论。其方案应当兼顾时间复杂度与准确性，对具有创新性的想法和内容，将给予一定加分。仿真实验程序中应包括必要的注释以保证可读性。
- D. 对于超过 1 人完成的作业，展示 PPT 中应在末页注明各成员贡献比例（如 1 : 0.9），并说明每位成员负责的工作内容。没有分工说明或说明不充分的报告将被予以一定程度的扣分。
- E. 作业应独立完成。一经发现抄袭现象，抄袭与被抄袭者的成绩均以 0 分计。实验代码或仿真程序的主体部分应自己编写，直接调用网上公开的程序代码应在代码文件的相应位置进行注释，并在报告中对出处进行引用。使用过多的公开代码会影响报告得分。
- F. 所有小组需在最终报告截止前提交所有相关资料。截止时间为 12.18（14 周周日）晚。没有按时完成的小组将被扣分。所有小组都应当为课堂展示做好准备，我们会根据完成情况进行课上展示抽查。

## 2 课题研究内容

在以下两项课题中 **任选一项** 完成：

课题中涉及的测试图片资源可于 <https://cloud.tsinghua.edu.cn/d/32e8626b9f7e42e48a7c/> 获取。

### 2.1 图分割 (Graph Partitioning)

图 (graph) 是一种常见的可用于描述不同对象之间关系的数据结构，在多个领域均具有广泛的应用。数学上，一个简单无向图可用一个二元组定义： $G = (V, E)$ 。其中， $V = \{v_1, \dots, v_n\}$  是顶点 (vertex) 集合， $E = \{e_{ij}\}$  是边 (edge) 集合，其中  $e_{ij}$  表示连接顶点  $v_i$  和  $v_j$  的边。我们假定任意一条边  $e_{ij} \in E$  具有权重  $w_{ij} \geq 0$ ，并定义加权邻接矩阵 (weighted adjacency matrix)  $W = (w_{ij})_{i,j=1,\dots,n}$ ，其中，如果顶点  $i$  和  $j$  之间没有边，则对应的权重  $w_{ij} = 0$ 。<sup>1</sup>对任意两个顶点  $u, v \in V$ ，我们用  $w(u, v)$  表示连接顶点  $u$  和  $v$  的边上的权重。对任意顶点  $v_i \in V$ ，定义它的度 (degree) 为其到其他所有顶点的权重之和，即为  $d_i = \sum_{j=1}^n w_{ij}$ ，进而定义度矩阵 (degree matrix)  $D = \text{diag}(d_1, \dots, d_n)$ 。

在本次课题中，我们考虑图分割 (graph partition) 任务，其目的是找出  $V$  的两个子集  $A, B$  满足  $A \cup B = V$ ， $A \cap B = \emptyset$ ，并最小化  $A$  和  $B$  对应的子图间的相似度。在图论领域，这样的相似度可以用 cut 来度量：

$$\text{cut}(A, B) := \sum_{u \in A, v \in B} w(u, v).$$

对由最小化 cut 来定义的图分割问题，存在多种方法可以高效求解其全局最优解。但是在实际应用中，更常用的优化目标是最小化 normalized cut (Ncut) 或 RatioCut：

$$\text{Ncut}(A, B) := \frac{\text{cut}(A, B)}{\sum_{u \in A, t \in V} w(u, t)} + \frac{\text{cut}(A, B)}{\sum_{v \in B, t \in V} w(v, t)},$$

$$\text{RatioCut}(A, B) := \frac{\text{cut}(A, B)}{|A|} + \frac{\text{cut}(A, B)}{|B|}.$$

可以证明，根据 Ncut 和 RatioCut 定义的图分割问题是 NP 难的。但通过一定的松弛，可以高效地求取其近似解。更多的介绍和讨论可参考 [1] 及其中的参考文献。

本研究内容共 4 个要求，如下：

**要求 1.** 简述最小化 Ncut 和 RatioCut 相比于最小化 cut 的优势。

**要求 2.** 进行理论推导，分别将最小化 Ncut 和 RatioCut 的优化目标等价转化为和矩阵  $W$ 、 $D$  等有关的形式，并进行适当的松弛以得到近似解。

**要求 3.** 编程实现上一要求中得到的图分割算法，并分析算法的时间复杂度。

**要求 4.** 在给定测试图片上利用图分割算法进行近似的图像分割，并对比基于 Ncut 和基于 RatioCut 的结果。提示：需要考虑如何定义图片中不同像素点之间的权值、如何确定合适的分割次数等。

<sup>1</sup>注意这里图的简单性保证了  $w_{ii} = 0$ ，无向性保证了  $w_{ij} = w_{ji}$ 。

## 2.2 鲁棒主成分分析 (RPCA)

在计算机视觉与模式识别任务中,通常都假设观测数据近似存在于一个低维的子空间下。为找出这样的子空间,经典的主成分分析 (PCA) 方法假定数据受到较小的高斯噪声污染,即数据  $\mathbf{D}$  由一个低秩矩阵  $\mathbf{A}$  和一个独立同分布的高斯噪声矩阵  $\mathbf{E}$  构成。当给定超参数  $\text{rank}(\mathbf{A})$  时,该任务可以建模为如下的优化问题:

$$\min_{\mathbf{A}, \mathbf{E}} \|\mathbf{E}\|_F, \quad \text{s.t.} \quad \text{rank}(\mathbf{A}) \leq r, \quad \mathbf{D} = \mathbf{A} + \mathbf{E}$$

这是一个凸问题,可以通过对矩阵  $\mathbf{D}$  进行奇异值分解,得到最优解析解。

然而在实际应用中,若出现较高幅度的尖锐噪声或严重的离群点时,PCA 的性能会受到很大的影响。而另一方面,当噪声矩阵  $\mathbf{E}$  足够稀疏时,原始的低秩矩阵仍然可能被恢复。该任务可以建模为如下的优化问题:

$$\min_{\mathbf{A}, \mathbf{E}} \text{rank}(\mathbf{A}) + \lambda \|\mathbf{E}\|_0, \quad \text{s.t.} \quad \mathbf{D} = \mathbf{A} + \mathbf{E}$$

其中  $\|\mathbf{E}\|_0$  是一个常用的不严格矩阵 0-范数定义,指矩阵中非零元素的个数。由于  $\text{rank}(\mathbf{A})$  和  $\|\mathbf{E}\|_0$  都是非凸的,直接优化该问题非常困难,因此需要对其进行凸松弛。

对于范数  $\text{rank}(\mathbf{A})$ ,一种松弛方法是使用核范数  $\|\mathbf{A}\|_* = \text{tr}(\sqrt{\mathbf{A}^T \mathbf{A}})$ ,即该矩阵奇异值的和;对于矩阵 0-范数  $\|\mathbf{E}\|_0$ ,其常规的松弛方法是使用 1-范数  $\|\mathbf{E}\|_1 = \max_j \sum_{i=1}^m |e_{i,j}|$ 。由此,原问题被转换为如下凸优化问题:

$$\min_{\mathbf{A}, \mathbf{E}} \|\mathbf{A}\|_* + \lambda \|\mathbf{E}\|_1, \quad \text{s.t.} \quad \mathbf{D} = \mathbf{A} + \mathbf{E}$$

这被称为鲁棒主成分分析 (Robust Principal Component Analysis) [2]。使用梯度下降法理论上即可获得其全局最优解;具有更强收敛性的其他针对性优化方法,在综述 [3] 中有总结。

本研究内容共 4 个要求,如下:

- 要求 1.** 请利用矩阵运算的求导法则,写出一种通用优化方法(如梯度下降等)直接求解该问题时的计算过程,并编程实现之:要求输入原始数据矩阵  $\mathbf{D}$ ,给出相应的低秩矩阵  $\mathbf{A}$ (可使用常规的矩阵计算库函数,但若使用 Autograd 等自动求导框架会适当减分)。
- 要求 2.** 选择一种针对该问题的特殊优化算法,简述其原理;写出相应公式和算法,并编程实现之;通过实验比较其收敛速度与上一问实现的算法的差异。
- 要求 3.** 除 RPCA 以外,还有许多低秩矩阵恢复 (Low-Rank Matrix Restoration) 模型能解决类似问题,如矩阵补全 (Matrix Completion),低秩表示 (Low-Rank Representation) 等。其建模方法略有不同。请任选一种模型,对其优化目标进行详细介绍与推导,写出一种相应优化算法的流程,并编程实现之。
- 要求 4.** 自选指标,在给定测试图片上对 PCA, RPCA 以及你所选择的方法进行对比,展示其低秩成分图与噪声图,分析其效果优劣、去噪特性,以及各超参数的影响;也可自选图片作为补充。

## 初始参考文献

- [1] Von Luxburg U. A tutorial on spectral clustering[J]. Statistics and computing, 2007, 17(4): 395-416.
- [2] Candès E J, Li X, Ma Y, et al. Robust principal component analysis?[J]. Journal of the ACM (JACM), 2011, 58(3): 1-37.
- [3] 史加荣, 郑秀云, 魏宗田, 等. 低秩矩阵恢复算法综述 [J]. 计算机应用研究, 2013, 30(6): 1601-1605.